

Beyond Self-attention: External Attention using Two Linear Layers for Visual Tasks

Paper Information

- Paper ID:** 2105_02358v2
- Data Type:** 计算机视觉多任务数据（图像分类、目标检测、语义分割、实例分割、图像生成、点云分类与分割）
- Organism:** 不适用（计算机视觉研究）
- Pages Analyzed:** 11
- Figures Extracted:** 176

Analysis Pipeline

Step 1: 核心方法：外部注意力机制

Description: 实现外部注意力（External Attention, EA）模块，用两个可学习的外部记忆单元替代自注意力。输入特征与键记忆单元计算注意力图，再与值记忆单元相乘得到输出特征。复杂度从 $O(N^2)$ 降至 $O(N)$ 。

Tools: PyTorch, Jittor

Input: 特征图 $F \in R^{(B \times N \times C)}$ ，其中B为批大小，N为像素/元素数量，C为通道数

Output: 精炼特征图 $F_{out} \in R^{(B \times N \times C)}$

Parameters: - `memory_units_S`: 64（推荐值，可取值8, 32, 64, 256） - `normalization`: 双归一化（先列后行） - `linear_layer_bias`: False - `dimension_d`: 与输入特征维度一致 - `algorithm`: $A = \text{softmax}(\text{l1_norm}(F \times M_k^T))$; $F_{out} = A \times M_v$

Example Command:

```
# 伪代码见Algorithm 1
attn = M_k(F) # shape=(B, N, M)
attn = softmax(attn, dim=1)
attn = l1_norm(attn, dim=2)
out = M_v(attn) # shape=(B, N, C)
```

Best Practice Note: 记忆单元数量 S 远小于 N （如 $S=64$ 时性能良好），双归一化对外部注意力效果至关重要。线性层不使用偏置项以增强正则化。

Step 2: 多头外部注意力机制

Description: 将外部注意力扩展为多头版本（Multi-head EA），共享跨头的记忆单元，最后通过线性变换 W_o 整合各头输出。平衡头数 H 和记忆单元数 S （可同步缩放）。

Tools: PyTorch, Jittor

Input: 特征图 $F \in \mathbb{R}^{(B \times N \times C_{in})}$

Output: 多头精炼特征图 $F_{out} \in \mathbb{R}^{(B \times N \times C_{in})}$

Parameters: - `num_heads_H`: 16, 24, 32（根据模型规模） - `memory_units_S`: 64（多头间共享） - `head_dim`: $C // H$ - `Wo_linear`: 最终整合变换矩阵

Example Command:

```
# 伪代码见Algorithm 2
F = query_linear(F).view(B, N, H, C//H).permute(0,2,1,3)
attn = M_k(F) # shape=(B, H, N, M)
attn = softmax(attn, dim=2)
attn = l1_norm(attn, dim=3)
out = M_v(attn) # shape=(B, H, N, C//H)
out = out.permute(0,2,1,3).view(B, N, C)
out = W_o(out)
```

Best Practice Note: 多头机制对外部注意力至关重要，不同头可捕获不同特征关系。记忆单元跨头共享减少参数，最终线性层Wo确保输入输出维度一致。

Step 3: 消融实验 (PASCAL VOC分割)

Description: 在PASCAL VOC验证集上验证外部注意力模块的有效性，对比自注意力、不同记忆单元数和归一化方法。采用FCN作为骨干网络。

Tools: Jittor, PyTorch, FCN, ResNet

Input: PASCAL VOC训练集 (10,582图像) 和验证集 (1,449图像) , 20类前景+背景

Output: mIoU精度指标和模型对比结果

Parameters: - backbone : ResNet-50/101 - batch_size : 12 -
iterations : 30000 - optimizer : 未明确提及, 推测为SGD/Adam -
learning_rate : 未明确提及 - output_stride : 16 (部分实验为8) -
memory_units_S : [8, 32, 64, 256] - normalization_methods :
['DoubleNorm', 'Softmax']

Example Command:

无明确命令，参考mmsegmentation框架配置

Best Practice Note: DoubleNorm归一化对外部注意力至关重要，S=64时性能最佳 (mIoU 77.4%)，输出步长OS=8优于16。外部注意力优于自注意力 (+1.2% mIoU)。

Step 4: 图像分类实验 (ImageNet-1K)

Description: 在ImageNet-1K数据集上评估外部注意力，替换T2T-ViT中的Performer和多头自注意力模块。测试不同模型规模 (7/14/19) 和输入分辨率。

Tools: PyTorch, T2T-ViT, Performer

Input: ImageNet-1K数据集 (128万训练图像, 1k类别)

Output: Top-1准确率、模型参数、吞吐量

Parameters: - `models` : ['T2T-ViT-7', 'T2T-ViT-14', 'T2T-ViT-19'] -
`input_resolution` : 224×224, 384×384 - `num_heads` : [1, 4, 6, 16, 24, 32] - `memory_units_S` : [64, 128, 256] - `epochs` : 未明确提及, 参考T2T-ViT设置 (通常为300) - `optimizer` : AdamW - `learning_rate` : 未明确提及 - `batch_size` : 未明确提及

Example Command:

基于T2T-ViT代码库, 替换attention模块为外部注意力

Best Practice Note: 外部注意力与Performer相当, 多头外部注意力在24头64记忆单元时达79.3% Top-1。EAMLP全MLP架构在79.4% Top-1, 但LN换BN在大模型会训练失败。

Step 5: 目标检测与实例分割 (COCO)

Description: 在MS COCO数据集上, 基于MMDetection工具包, 在ResNet-50骨干网络第4阶段后插入外部注意力模块, 评估检测和分割性能。

Tools: MMDetection, PyTorch, ResNet, Faster R-CNN, Mask R-CNN, Cascade R-CNN

Input: COCO数据集 (20万+图像, 80类, 50万+标注实例)

Output: Box AP和Mask AP指标

Parameters: - `external_attention_position` : ResNet stage 4末端 -
`backbone` : ResNet-50 - `detectors` : ['Faster R-CNN', 'Mask R-CNN', 'RetinaNet', 'Cascade R-CNN'] - `batch_size` : 未明确提及, 使用MMDetection默认配置 - `iterations` : 未明确提及

Example Command:

在MMDetection配置文件中添加EA模块到backbone的stage4

Best Practice Note: 在COCO任务中, 仅添加1个外部注意力模块可带来约1% AP提升 (Box AP 40.3→41.4, Mask AP 34.7→35.4), 计算开销增加极小。

Step 6: 语义分割实验

Description: 在PASCAL VOC、ADE20K和Cityscapes数据集上进行语义分割。采用EANet架构（FCN+外部注意力），膨胀ResNet-101作为骨干。

Tools: mmsegmentation, PyTorch, ResNet-101, FCN

Input: PASCAL VOC（10,582训练）、ADE20K（20K训练）、Cityscapes（2,975训练）

Output: mIoU指标（多尺度+翻转测试）

Parameters: - backbone : Dilated ResNet-101 - output_stride : 8 - learning_rate : 0.009（PASCAL VOC），其他数据集采用 mmsegmentation默认 - batch_size : 16（PASCAL VOC），其他未明确 - iterations : {'pascal_voc': '45k + 15k微调', 'ade20k': '160k', 'cityscapes': '80k'} - optimizer : poly-learning rate policy - input_size : 513×513（PASCAL VOC） - test_time_augmentation : 多尺度+翻转测试

Example Command:

```
mmsegmentation configs: --lr 0.009 --iters 45000 --batch-size 16
```

Best Practice Note: 在ADE20K上达到45.33% mIoU，优于DANet等自注意力方法。双归一化和膨胀卷积结合是关键。

Step 7: 图像生成实验（EAGAN）

Description: 将SAGAN中的自注意力替换为外部注意力构建EAGAN，在CIFAR-10和Tiny-ImageNet数据集上评估生成质量。使用PyTorch-StudioGAN框架。

Tools: PyTorch, PyTorch-StudioGAN, SAGAN, DCGAN, LSGAN, WGAN-GP

Input: CIFAR-10（32×32图像）、Tiny-ImageNet（64×64图像）

Output: FID和IS评估指标、生成图像样本

Parameters: - generator_attention : 外部注意力替换自注意力 - discriminator_attention : 外部注意力替换自注意力 -

`hyperparameters` : SAGAN默认配置 - `evaluation_metrics` : ['FID', 'IS']

Example Command:

基于PyTorch-StudioGAN, 修改attention层为外部注意力实现

Best Practice Note: 在CIFAR-10上FID 14.105/IS 8.630, 优于SAGAN。外部注意力在生成任务中同样有效且更高效。

Step 8: 点云分析实验

Description: 在3D点云任务中, 将PCT模型中的自注意力替换为外部注意力(EAT), 评估ModelNet40分类和ShapeNet部件分割性能。

Tools: PyTorch, PCT, Jittor

Input: {'modelnet40': '12,311 CAD模型 (40类, 9,843训练/2,468测试)', 1,024点', 'shapenet': '14,006训练/2,874评估3D模型 (16类, 50部件标签)', 1,024点}'

Output: {'modelnet40': '整体分类准确率', 'shapenet': '部件平均交并比ploU'}

Parameters: - `num_points` : 1024 - `augmentation` : ['随机平移', '各向异性缩放', '随机失活'] - `follows_pct` : 遵循PCT实验设置 - `memory_units_S` : 64 (隐含) - `num_heads` : 24 (隐含)

Example Command:

修改PCT代码的attention层实现为外部注意力

Best Practice Note: ModelNet40上达93.4%准确率 (优于PCT 93.2%), ShapeNet ploU 86.5。外部注意力在3D任务中同样有效, 可学习跨样本的全局几何特征。

Step 9: 效率对比分析

Description: 对比外部注意力与自注意力及其变体 (Non-local, A2-Net, APC等) 在参数量和计算量 (MACs) 上的差异。输入尺寸1×512×128×128。

Tools: PyTorch

Input: 标准输入特征图 $1 \times 512 \times 128 \times 128$

Output: 参数量 (M) 和乘加运算量 (MACs, G)

Parameters: - `input_shape` : [1, 512, 128, 128] - `comparison_methods` : ['SA[16]', 'DA[4]', 'A2[83]', 'APC[61]', 'DM[84]', 'ACF[85]', 'Ham[8]']

Example Command:

```
torchprof或thop库测量模型复杂度
```

Best Practice Note: 外部注意力参数量0.55M（自注意力的一半），MACs 9.2G（32倍速），相比最佳变体Ham仍快2倍。线性复杂度优势显著。

Databases Used

- ImageNet-1K（图像分类）[89]
- MS COCO（目标检测/实例分割）[93]
- PASCAL VOC（语义分割）[88]
- ADE20K（语义分割）[94]
- Cityscapes（城市场景分割）[95]
- CIFAR-10（图像生成）
- Tiny-ImageNet（图像生成）
- ModelNet40（点云分类）[99]
- ShapeNet Part（点云分割）[100]

Key Methodological Findings

- 外部注意力通过两个可学习共享内存单元实现线性复杂度 $O(N)$ ，替代自注意力的二次复杂度 $O(N^2)$
- 双归一化（先列后行）对外部注意力性能至关重要，比softmax提升约2% mIoU

- 在PASCAL VOC分割任务中，外部注意力平均提升1.2% mIoU，优于自注意力
- EAMLP全MLP架构在ImageNet上达79.4% Top-1准确率，与CNN和Transformer相当
- 在COCO检测/分割任务中，仅添加1个外部注意力模块可提升1% AP
- 在ADE20K分割上达45.33% mIoU，超越DANet、OCRNet等自注意力方法
- EAGAN在CIFAR-10上FID 14.105，优于SAGAN的14.498，生成质量更高
- 点云任务中EAT在ModelNet40上达93.4%准确率，ShapeNet pIoU 86.5，均优于PCT
- 计算效率：参数量减半，推理速度32倍于标准自注意力，比最优变体快2倍
- 内存单元数量S=64为经验最优值，平衡性能与效率；头数H与S可灵活权衡