

OffSeeker: Online Reinforcement Learning Is Not All You Need for Deep Research Agents

Paper Information

- **Paper ID:** 2601_18467v1
- **Data Type:** 文本数据、QA对、SFT轨迹、DPO偏好数据
- **Organism:** 不适用 (AI模型研究)
- **Pages Analyzed:** 24
- **Figures Extracted:** 7

Analysis Pipeline

Step 1: 数据合成框架 - DeepForge

Description: 通过真实网络交互合成大规模深度研究任务，包含可扩展实体扩展和复杂问题生成两个阶段

Tools: DeepSeek-v3.1, html2text, 网络搜索API

Input: 随机名词种子、网页URL、实体描述

Output: 66k高质量多跳QA对 (DeepForge-QA)

Parameters: - 种子名词批量大小：可配置 (示例中为B) - 最大并行工作线程：W - 实体探索深度分布：Pdepth - 问题生成模型：DeepSeek-v3.1 - 优先实体类型：长尾低频实体

Example Command:

算法1: DeepForge数据合成管道 (见附录A.2.1)

Best Practice Note: 使用LLM生成多样化初始实体，通过迭代网络搜索和实体提取避免依赖静态Wikipedia资源，确保数据时效性和多样性

Step 2: 实体图构建

Description: 基于扩展的实体集构建以实体为中心的知识图谱，通过多步遍历获取实体属性及关系链接

Tools: 轻量化搜索代理, LLM实体提取

Input: 清洗后的实体池E

Output: 实体图G_e (包含实体属性与关系)

Parameters: - 探索深度：从Pdepth分布采样 - 关系提取提示：附录A.2.2中的ExploreEntityGraph提示词 - 实体优先级：低频率、文档稀疏的关系

Best Practice Note: 递归沿低频关系扩展以生成丰富的跨实体依赖图，为后续复杂问题生成提供上下文

Step 3: SFT数据构建与过滤

Description: 使用专有模型在真实互联网环境中采样轨迹，并通过多级质量检查获得高质量监督微调数据

Tools: 专有模型（未明确版本），LLM评估器

Input: DeepForge-QA的66k问题

Output: 33k高质量SFT轨迹

Parameters: - 过滤检查项：['无效工具结果检查', '格式错误检查', 'token长度检查 (8,192-131,072 tokens)', '答案正确性检查 (语义等价评估)', '整体质量检查 (幻觉、逻辑错误等)'] - 质量评估提示：附录A.4中的Quality Check Prompt - 数据集混合：DeepForge数据+少量开源其他任务数据

Best Practice Note: 严格的多阶段过滤确保轨迹质量，包括工具调用验证、认知一致性检查和逻辑错误检测

Step 4: 监督微调 (SFT)

Description: 在高质量轨迹上进行标准自回归监督微调，使用长序列支持以容纳多步工具交互

Tools: Qwen3-8B, 360-LLaMA-Factory, cosine_with_min_lr调度器

Input: 33k SFT轨迹

Output: SFT训练后的OffSeeker-8B模型

Parameters: - 基础模型 : Qwen3-8B - 最大序列长度 : 128k tokens - 初始学习率 : 3e-5 - 最小学习率 : 1e-7 - warmup比例 : 0.1 - 训练轮次 : 3 epochs - 全局batch size : 512 - 优化器 : 未明确指定 (框架默认) - 硬件 : 64×NVIDIA H20 GPUs (80GB)

Example Command:

使用360-LLaMA-Factory进行序列并行训练

Best Practice Note: 采用长序列训练策略支持长程推理，结合Cosine调度器稳定训练过程

Step 5: 偏好数据构建

Description: 使用SFT模型生成候选轨迹，通过LLM评估器打分并构建DPO偏好对

Tools: SFT训练后的模型, LLM评估器 (DeepSeek-V3.1)

Input: SFT模型生成的多候选轨迹

Output: 21k高质量DPO偏好对 (选择vs拒绝轨迹)

Parameters: - 评估维度 : ['逻辑一致性', '事实正确性', '整体解决方案质量'] - 配对策略 : 每任务选最高和最低分轨迹，穷尽配对成4对 - 过滤条件 : 仅保留优选轨迹得分严格高于拒绝轨迹的样本 - 评估模型 : DeepSeek-V3.1 (用于答案提取和网页摘要)

Best Practice Note: 离线构建偏好数据避免在线交互成本，通过严格筛选确保偏好信号质量

Step 6: 直接偏好优化 (DPO)

Description: 离线RL方法优化模型以偏好高质量轨迹，无需在线环境交互

Tools: DPO算法, SFT模型 (参考策略 π_{ref})

Input: 21k DPO偏好对

Output: 最终OffSeeker-8B (DPO)模型

Parameters: - 最大序列长度 : 48k tokens - 学习率 : $1e-6$ - 最小学习率 : $1e-7$ - warmup比例 : 0.1 - 训练轮次 : 1 epoch (200步后选择结果) - 全局batch size : 512 - β 参数 : 未明确指定 (原文仅提及控制强度) - 参考策略 : 冻结的SFT模型

Example Command:

DPO目标函数: $LDPO(\theta) = -E[\log \sigma(\beta(\Delta\theta(T+) - \Delta\theta(T-)))]$

Best Practice Note: 离线DPO避免在线RL的高API成本和稳定性问题，在保持接近SFT策略的同时提升偏好轨迹概率

Step 7: 智能体框架部署

Description: 采用ReAct风格框架，支持工具调用与推理交替执行

Tools: search, visit_urls, search_wiki, code_execution

Input: 用户查询q、工具模式定义

Output: 完整交互轨迹T (含推理r、动作a、环境反馈o和最终答案)

Parameters: - 框架类型 : ReAct-style [32] - 工具数量 : 4个核心工具 - 最大处理时间 : 每任务10分钟 (GRPO实验设置) - 轨迹格式 : , , , 标签

Best Practice Note: 显式分离推理与动作，通过环境反馈迭代优化决策

Step 8: 评估与验证

Description: 在六个挑战性基准上评估模型性能，使用Pass@1指标

Tools: Serper API, Jina API, DeepSeek-V3.1 (摘要), LLM-as-Judge

Input: 测试基准问题

Output: 模型性能得分

Parameters: - 评估基准: ['GAIA', 'BrowseComp-zh/en', 'HLE', 'XBench-DeepSearch', 'WebWalkerQA'] - 评估指标: Pass@1 - 搜索API: Serper API (1K调用=\$1) - 内容提取: Jina API - 网页摘要模型: DeepSeek-V3.1

Best Practice Note: 使用真实互联网环境评估确保泛化能力，LLM-as-Judge提供可扩展的自动评估

Databases Used

- Serper API (网络搜索)
- Jina API (网页内容提取)
- Wikipedia (search_wiki工具)
- LibreTexts CK-12化学材料 (密度数据示例)
- 六个评估基准数据集

Key Methodological Findings

- 离线训练策略达到与在线RL相当的效果：OffSeeker-8B在多个基准上超越30B参数在线RL训练的模型
- 数据质量与规模正相关：BrowseComp-zh准确率从2k样本的19.7%提升至33k样本的24.2%
- 上下文长度关键：128k上下文窗口性能是32k窗口的3倍 (BrowseComp-zh: 29.97% vs 3.48%)
- 模型规模效应：OffSeeker-14B (DPO) 在GAIA上达54.4%，比8B模型提升2.9%
- 成本优势：离线训练API成本接近零，相比GRPO在线RL 50步训练花费约\$350

- DPO一致性改进：在所有基准上DPO版本均优于SFT版本，平均提升2.5-3.9分

Report generated by Paper Reader Workflow