

PANGEA: A FULLY OPEN MULTILINGUAL MULTI-MODAL LLM FOR 39 LANGUAGES

Paper Information

- **Paper ID:** 2410_16153v1
- **Data Type:** 多模态指令微调数据（图像-文本对）
- **Organism:** 不适用
- **Pages Analyzed:** 52
- **Figures Extracted:** 85

Analysis Pipeline

Step 1: 英文指令数据收集

Description: 从现有开源数据集中收集高质量的英文多模态指令数据，涵盖视觉理解、图表问答、图像描述、纯文本指令（代码、数学）等多种任务类型

Tools: 人工收集, 学术数据集

Input: 原始英文多模态数据集（LLaVA、Cambrian、ChartQA等）及纯文本数据集（Code-Feedback、NuminaMath、OpenHermes-2.5）

Output: 高质量英文指令池

Parameters: - 数据来源：LLaVA-4V, Cambrian, LVIS-Instruct4V, ChartQA, Doc-VQA, 等 - 数据规模：约250万英文样本

Example Command:

人工筛选和整理现有数据集

Best Practice Note: 使用经过验证的高质量数据集作为翻译基础；确保数据覆盖多样化的视觉理解任务和纯文本任务

Step 2: 机器翻译指令

Description: 将英文指令翻译成39种语言。初始尝试开源NLLB-3B模型但效果不佳，最终采用专有Gemini 1.5 Pro模型进行翻译，确保复杂指令场景和代码/数学领域的翻译质量

Tools: Gemini 1.5 Pro, NLLB-3B (已弃用)

Input: 高质量英文指令池

Output: 39种语言的翻译指令数据

Parameters: - 翻译模型：Gemini 1.5 Pro - 目标语言：39种类型多样的语言 - 翻译策略：直接翻译整批指令

Example Command:

通过API调用Gemini 1.5 Pro进行批处理翻译

Best Practice Note: 对于复杂指令，建议使用GPT-4级别以上的大语言模型而非传统MT模型；翻译后需进行质量检查，特别是代码关键字和数学符号的准确性

Step 3: 翻译后处理

Description: 开发自动化后处理管道，修正翻译后数据中的不一致问题，如对话轮次不匹配、多选题选项缺失等，确保所有翻译指令的一致性

Tools: 自定义后处理管道

Input: 原始翻译指令数据

Output: 清洗后的翻译指令数据

Parameters: - 错误类型：对话轮次不匹配、选项缺失 - 处理方式：自动修正或直接丢弃问题样本

Example Command:

```
python post_process_translations.py --input translated.json --output cl
```

Best Practice Note: 未提供具体实现细节。建议实施规则基础检查（如JSON结构验证、选项数量匹配）和统计异常检测

Step 4: 文化多样性图像筛选

Description: 从LAION-Multi数据集中采样1000万张图像，通过启发式过滤和LLM评分筛选出100万张高质量、文化特异性的图像

Tools: LAION-Multi, CLIP, Llama-3.1-8B-Instruct

Input: LAION-Multi数据集（1000万张图像及alt文本）

Output: 100万张文化相关的高质量图像及元数据

Parameters: - 启发式过滤条件: {'图像尺寸': '224-4096像素', '宽高比': '0.25-3.0', '文本长度': '5-5000字符', 'CLIP分数': '>0.3', 'NSFW内容': '排除', '重复内容': '去重'} - LLM评分标准: {'模型': 'Llama-3.1-8B-Instruct', '文本质量评分': '1-5分, 保留≥4分', '主题分类': '11个预定义类别', '国家/地区分类': '识别特定文化关联'} - 最终筛选: 排除'无特定国家'图像（约60%），避免过度采样常见主题

Example Command:

```
python cultural_filter.py --images laion_multi/ --clip-score 0.3 --llm-m
```

Best Practice Note: CLIP分数阈值0.3确保图文对齐；LLM评分剔除低质量描述；保持地理和主题平衡以避免偏见

Step 5: 多文化图像重描述

Description: 使用Gemini 1.5 Pro基于筛选后的高质量alt文本，为每张图像生成详细的文化相关描述，使用图像原产国的语言

Tools: Gemini 1.5 Pro

Input: 筛选后的图像 + 高质量alt文本 + 文化元数据（国家、主题）

Output: 多语言详细图像描述

Parameters: - 生成模型 : Gemini 1.5 Pro - 描述语言 : 图像文化原产国语言 - 提示策略 : 5种变体的prompt模板, 包含国家、主题和原alt文本信息

Example Command:

```
gemini.generate_caption(prompt=f'请用{language}详细描述这张可能关联{country}
```

Best Practice Note: 利用原alt文本中的文化特定信息 (如地点、人物身份) 增强描述细节; 多prompt变体可增加多样性

Step 6: 多文化指令生成

Description: 基于详细描述, 使用Gemini 1.5 Pro生成最多2个QA指令对, 从13个预定义任务类型中选择, 确保指令多样性和文化敏感性

Tools: Gemini 1.5 Pro

Input: 多语言详细图像描述

Output: 指令-响应对 (最多2个/图像)

Parameters: - 生成模型 : Gemini 1.5 Pro - 任务类型 : 13种 (信息检索、代码调试、创造性写作、批判性推理、规划策略、数学思维、文本修订、数据分析、角色扮演、头脑风暴、建议寻求、学习理解、文化解读) - 每图像样本数 : 最多2个不同任务类型的QA对

Example Command:

```
gemini.generate_instruction(caption, language, task_types=13, max_pairs
```

Best Practice Note: 显式指定任务类型可确保指令多样性; 限制每图像样本数避免过拟合特定视觉内容

Step 7: 开源数据集整合

Description: 调研并整合现有高质量开源多语言多模态数据集, 补充语言和文化覆盖

Tools: HuggingFace数据集

Input: 多个开源数据集

Output: 整合后的多语言数据子集

Parameters: - 整合数据集 : ['Chinese ALLaVA-4V', 'Viet Document and OCR QA', 'Llava Chinese', 'Llava Medical Chinese Instruction', 'LLaVA-Japanese-Instruct', 'MTVQA', 'Japanese STAIR Captions', 'Russian GQA', 'French Doc-VQA', 'French Table-VQA']

Example Command:

```
datasets.load_dataset()
```

Best Practice Note: 保留原始数据格式和质量标准；确保语言和文化多样性覆盖

Step 8: 数据集混合

Description: 将翻译数据、文化理解数据和开源数据混合，构建最终的PANGAEA INS训练集，保持英文与多语言40%:60%的比例

Tools: 数据混合脚本

Input: 翻译指令、文化理解指令、开源指令

Output: PANGAEA INS (600万样本)

Parameters: - 总样本量 : 600万 - 英文比例 : 40% (250万) - 翻译数据 : 19% (120万) - 文化数据 : 24% (150万) - 开源数据 : 17% (100万) - 多语言比例 : 60% (370万)

Example Command:

```
python mix_dataset.py --ratio en:40 --ratio mul:60 --output pangea_ins.j
```

Best Practice Note: 实验表明40%英文数据最有利于跨语言迁移；过度依赖英文会损害多语言性能

Step 9: 模型训练

Description: 基于LLaVA-Next架构, 使用Qwen2-7B-Instruct作为语言模型主干, 在PANGAEA INS上进行指令微调

Tools: LLaVA-Next架构, Qwen2-7B-Instruct, PyTorch/Transformer框架

Input: PANGAEA INS数据集

Output: PANGAEA-7B模型

Parameters: - 基础架构 : LLaVA-Next - 语言模型主干 : Qwen2-7B-Instruct - 学习率 : 2e-5 - 批大小 : 512 - 训练轮次 : 1 epoch - 调度器 : cosine decay with 0.03 warmup steps - 优化器 : 未明确提及, 假设为AdamW

Example Command:

```
torchrun --nproc_per_node=8 train.py --model llava-next-qwen2-7b --data
```

Best Practice Note: 1 epoch训练防止过拟合; 大batch size (512) 配合cosine调度器是标准做法; warmup比例3%适中

Step 10: OCR能力增强 (探索性)

Description: 构建50万条多语言OCR指令数据 (10种语言, 每种5万条), 专门提升模型对网页截图文本提取能力

Tools: 网页截图工具, OCR标注流程

Input: 各国网站截图

Output: 多语言OCR训练集

Parameters: - 数据规模 : 50万条 - 语言数量 : 10种 - 每语言样本 : 5万条 - 数据来源 : 网页用户界面截图

Example Command:

```
python collect_ocr_data.py --languages en,ar,es,fr,hi,id,js,ko,pt,zh --
```

Best Practice Note: 非拉丁文字（中文、日文、韩文）OCR准确率仍低于拉丁语言；需要更多样化的训练数据和字体覆盖

Step 11: 模型评估

Description: 使用PANGAEA BENCH进行全面评估，包含5个多模态任务和3个纯文本任务，覆盖14个数据集47种语言

Tools: lmms-eval, lm-evaluation-harness, GPT-4o（作为评估裁判）

Input: PANGAEA-7B模型 + 评估数据集

Output: 多任务性能指标

Parameters: - 评估框架：lmms-eval（多模态），lm-evaluation-harness（文本） - 多模态任务：['多模态对话', '图像描述', '文化理解', '多语言VQA', '多主题推理'] - 文本任务：['问答', '翻译', '推理'] - 评估裁判：GPT-4o（用于xChatBench细粒度评估） - 评分方式：1-5分制，后转换为0-100分

Example Command:

```
lmms-eval --model pangea-7b --tasks xgqa, mxm3600, cvqa --languages all
```

Best Practice Note: 使用LLM-as-Judge时提供细粒度评估标准比粗粒度提示更准确；必须检测语言幻觉（用langdetect）并对非目标语言回复评0分

Databases Used

- LAION-Multi（图像来源）
- LAION-5B
- ALLaVA-4V（中文多模态）
- Viet-Doc-VQA（越南语文档问答）
- Viet-OCR-VQA（越南语OCR问答）
- Llava-Med-Zh（中文医学）
- STAIR Captions（日语文本）
- GQA-ru（俄语视觉问答）
- Doc-VQA-Fr（法语文档问答）

- ChartQA (图表问答)
 - OpenHermes-2.5 (通用指令)
 - NuminaMath (数学推理)
 - xGQA (跨语言视觉问答)
 - MaXM (多文化VQA)
 - MaRVL (多文化推理)
 - XM3600/XM100 (多语言描述)
 - M3Exam (多语言教育考试)
 - MMMU (大学水平多模态推理)
 - TyDiQA (多样语言问答)
 - FLORES-200 (机器翻译)
 - MMMLU (多语言理解)
 - MGSM (多语言数学)
 - XStoryCloze (常识推理)
-

Key Methodological Findings

- PANGAEA-7B在英语任务上平均超越最强开源模型7.3分，在多语言任务上超越10.8分
 - 最优数据配比为40%英语 + 60%多语言，纯多语言数据反而导致性能下降
 - 随着多语言指令数据量增加，模型在英语和多语言任务上均呈现稳定的缩放效应
 - 低资源语言即使少量数据增加也能带来不成比例的性能提升，且存在类型相似语言间的正向迁移
 - 多模态大语言模型普遍存在语言幻觉问题（用英语回复非英语查询），需严格惩罚
 - 多语言OCR对非拉丁文字（中文、日文、韩文）的准确率显著低于拉丁语言，需要针对性数据增强
 - 在文本-only任务上，PANGAEA-7B保持甚至超越其Qwen2-7B-Instruct主干模型的性能，证明多模态训练未损害语言能力
 - xChatBench的细粒度LLM评估比粗粒度评估更能准确反映模型真实能力
-