

Visual Attention Network

Paper Information

- **Paper ID:** 2202_09741v5
- **Data Type:** 计算机视觉图像数据 (ImageNet, COCO, ADE20K 等标准数据集)
- **Organism:** 不适用 (本研究非生物信息学范畴)
- **Pages Analyzed:** 12
- **Figures Extracted:** 13

Analysis Pipeline

Step 1: 数据预处理与增强

Description: 为ImageNet图像分类任务准备训练数据，应用多种数据增强技术以提高模型泛化能力

Tools: PyTorch, Jittor, 图像处理库

Input: 原始RGB图像文件 (JPEG格式)

Output: 增强后的图像批次 (张量格式)

Parameters: - `random_cropping`: 随机裁剪 - `random_horizontal_flipping`: 随机水平翻转 - `label_smoothing`: 标签平滑 - `mixup_alpha`: mixup增强 - `cutmix_alpha`: cutmix增强 - `random_erasing_prob`: 随机擦除 - `image_size`: 224×224 或 384×384 - `normalization`: ImageNet标准归一化

Example Command:

论文未提供具体命令，但提到遵循DeiT[19]的训练方案

Best Practice Note: 论文使用了多种数据增强技术的组合，但未给出具体参数值。建议参考DeiT论文获取详细配置

Step 2: Large Kernel Attention (LKA) 模块构建

Description: 将大核卷积分解为三个部分以实现高效的长程依赖建模和自适应注意力机制

Tools: PyTorch, Jittor

Input: 输入特征图 $F \in \mathbb{R}^{(C \times H \times W)}$

Output: 加权后的特征图 $\text{Output} \in \mathbb{R}^{(C \times H \times W)}$

Parameters: - `kernel_size_K`: 21 - `dilation_rate_d`: 3 -
- `depthwise_conv_size`: 5×5 - `depthwise_dilated_conv_size`: 7×7
(`dilation`=3) - `pointwise_conv_size`: 1×1 -
- `normalization_function`: 无 (不使用sigmoid或softmax) - `operation`:
逐元素乘法 ($\otimes$)

Example Command:

```
Attention = Conv1×1(DW-D-Conv(DW-Conv(F))) → Output = Attention  $\otimes$  F
```

Best Practice Note: 论文通过消融研究确定K=21、d=3为最优配置。无需额外的归一化函数即可达到最佳性能

Step 3: Visual Attention Network (VAN) 模型构建

Description: 基于LKA模块构建分层视觉骨干网络，包含4个阶段的空间分辨率递减

Tools: PyTorch, Jittor

Input: 模型配置参数 (通道数C, 块数量L, 扩展率e.r.)

Output: VAN模型实例 (B0-B6不同规模)

Parameters: - `num_stages`: 4 - `stage_output_resolutions`: ['H/4×W/4', 'H/8×W/8', 'H/16×W/16', 'H/32×W/32'] - `expansion_ratios`: {'stage1-2':

8, 'stage3-4': 4} - activation_function : GELU -
normalization_layer : BatchNorm - feed_forward_network : 1×1
Conv → 3×3 DW Conv → GELU → 1×1 Conv - layer_scale_variant :
 $x_{out} = x + \text{diag}(\lambda)(f(x) + x)$, λ 初始值0.01

Example Command:

论文未提供模型构建的具体代码命令

Best Practice Note: 不同变体(B0-B6)通过调整每阶段的通道数C和块数量L实现。默认使用K=21的大核分解

Step 4: 模型训练 (ImageNet-1K)

Description: 在ImageNet-1K数据集上训练VAN模型300个epoch

Tools: AdamW优化器, PyTorch, Jittor, EMA

Input: 增强后的ImageNet训练图像 (1.28M张)

Output: 训练好的模型权重文件

Parameters: - optimizer : AdamW - momentum : 0.9 - weight_decay :
 5×10^{-2} - batch_size : 1024 - epochs : 300 - initial_learning_rate :
 5×10^{-4} - learning_rate_schedule : cosine schedule with warm-up -
ema_decay : 使用指数移动平均(EMA)提升训练 -
layer_scale_initial_value : 0.01

Example Command:

论文未提供具体训练脚本命令

Best Practice Note: 训练策略遵循DeiT等工作的标准实践，包括余弦退火学习率调整和预热策略

Step 5: 模型预训练 (ImageNet-22K)

Description: 在更大规模的ImageNet-22K数据集上进行预训练

Tools: AdamW优化器, PyTorch

Input: ImageNet-22K训练图像 (约14M张, 21841类)

Output: 预训练模型权重

Parameters: - `batch_size` : 8196 - `epochs` : 90 - `ema` : 不使用EMA -
`fine_tune_epochs` : 30

Example Command:

论文未提供具体预训练命令

Best Practice Note: 预训练后模型在ImageNet-1K上微调30个epoch, 支持224×224和384×384输入尺寸

Step 6: 下游任务微调

Description: 在目标检测、语义分割、实例分割等下游任务上微调VAN骨干网络

Tools: MMDetection, MMSegmentation, MMPose, OpenMMLab

Input: COCO、ADE20K等任务特定数据集

Output: 任务专用模型权重和预测结果

Parameters: - `detection_framework` : RetinaNet, Mask R-CNN, Cascade R-CNN, ATSS, GFL - `segmentation_head` : Semantic FPN, UperNet -
`panoptic_head` : Mask2Former - `pose_estimation` : SimpleBaseline -
`training_epochs` : 12或36个epoch - `pretrained_backbone` : ImageNet预训练的VAN权重

Example Command:

论文提到使用OpenMMLab代码库, 但未提供具体微调命令

Best Practice Note: 遵循Swin Transformer和PoolFormer等工作的相同训练/验证策略以确保公平比较

Step 7: 模型评估与可视化

Description: 在验证集上评估模型性能并生成类激活映射(CAM)可视化

Tools: Grad-CAM, 标准评估指标

Input: 验证集图像和训练好的模型

Output: 评估指标 (Top-1 Acc, AP, mIoU, PQ等) 和CAM可视化图

Parameters: - `evaluation_metrics` : {'classification': 'Top-1 accuracy (single crop)', 'detection': 'AP (IoU阈值0.5:0.95)', 'segmentation': 'mIoU', 'panoptic': 'PQ (Panoptic Quality)'} - `visualization_method` : Grad-CAM - `comparison_baselines` : ['Swin-T', 'ConvNeXt-T', 'ResNet', 'PVT']

Example Command:

论文未提供Grad-CAM实现代码

Best Practice Note: 使用Grad-CAM生成注意力热图，便于与Transformer和CNN方法进行定性比较

Databases Used

- ImageNet-1K (1.28M训练图像, 50K验证图像, 1000类)
- ImageNet-22K (约14M图像, 21841类)
- COCO 2017 (118K训练图像, 5K验证图像)
- COCO Panoptic Segmentation
- ADE20K (20K训练, 2K验证, 3K测试, 150类)
- CUB-200 (11,788图像, 200鸟类子类)
- DUTS (显著性检测)
- DUT-O (显著性检测)
- PASCAL-S (显著性检测)

Key Methodological Findings

- VAN-B6在ImageNet上达到87.8% Top-1准确率，超过同规模ViT和CNN

- VAN-B2在ADE20K语义分割上比Swin-T高4% mIoU (50.1 vs 46.1)
- VAN-B2在COCO目标检测上比Swin-T高2.6% AP (48.8 vs 46.2)
- VAN-B6在COCO全景分割上达到58.2 PQ, 创造新的SOTA性能
- LKA模块无需softmax/sigmoid归一化即可实现优异性能
- 大核卷积分解(K=21)在参数和计算量上显著优于标准卷积和MobileNet分解
- VAN在吞吐量-准确率权衡上优于Swin Transformer, 在RTX 3090上VAN-B0达2140 imgs/s

Report generated by Paper Reader Workflow