

端粒到端粒时代下的基因组组装

Paper Information

- **Paper ID:** 2308_07877v1
- **Data Type:** 全基因组测序(WGS) - 长读长测序数据
- **Organism:** 多物种综述 (人类、脊椎动物、植物、线虫、果蝇等)
- **Pages Analyzed:** 20
- **Figures Extracted:** 0

Analysis Pipeline

Step 1: 数据生成与测序

Description: 生成多种测序数据以支持高质量基因组组装，包括准确长读长、超长读长和长距离数据

Tools: PacBio HiFi, ONT ultra-long, ONT duplex, Hi-C, Pore-C, Strand-seq, stLFR, TELL-seq, haplotagging

Input: 基因组DNA样本

Output: 原始测序读长(FASTQ格式)

Parameters: - PacBio_HiFi : {'长度': '10-20 kb', '错误率': '<0.5%', '覆盖度': '≥15-fold per haplotype'} - ONT_ultra_long : {'长度': '>100 kb', '错误率': '~90-95% (v14 chemistry: 98-99%)', '覆盖度': '~10-fold (越高越好)} - HiC_trio : {'覆盖度': '30-fold usually sufficient'}

Example Command:

术中未提供具体命令

Best Practice Note: 对于二倍体样本，每个单倍型需要至少15倍覆盖度的准确长读长数据。超长读长数据可显著改善复杂重复区域的组装，即使覆盖度较低(10x)也有帮助。

Step 2: 读长错误校正

Description: 校正测序错误以提高读长准确性，这对于正确分离同源单倍型和重复拷贝至关重要

Tools: hifiasm, HiCanu, verkko, LJA

Input: 原始长读长数据(FASTQ)

Output: 校正后的读长序列

Parameters: - `hifiasm` : 在原始碱基空间进行校正 -

`HiCanu_verkko_LJA` : 在同聚物压缩空间进行校正 - `校正阈值` : 罕见碱基被校正（当其他重叠读长在相同位置不常见时）

Example Command:

术中未提供独立命令（集成在组装器中）

Best Practice Note: 虽然PacBio HiFi和ONT duplex读长已相当准确，但仍需错误校正。建议将错误校正步骤与组装步骤分离以便独立评估。大部分错误可被现有组装器有效校正。

Step 3: 初始组装图构建

Description: 从校正后的读长构建组装图（重叠图或de Bruijn图），生成不含长重复序列的线性片段(unitigs)

Tools: hifiasm, HiCanu, verkko, LJA, Shasta

Input: 校正后的长读长

Output: 初始组装图(GFA格式)、unitigs序列

Parameters: - `hifiasm_HiCanu` : 仅允许完美重叠（exact overlaps） -

`verkko_LJA` : 使用稀疏化的de Bruijn图（minimizer-based） - `重复长度阈`

值：~10 kb - k-mer大小：自适应选择（在重复区域用大k-mer，低覆盖区域用小k-mer）

Example Command:

```
hifiasm -o output -t 32 hifi_reads.fq.gz
```

Best Practice Note: 对于二倍体样本，组装图会呈现为一系列'bubble'结构，代表单倍型间的多态性。仅使用完美重叠的策略可更好地区分重复拷贝和单倍型。

Step 4: 超长读长整合与复杂区域解析

Description: 将ONT超长读长锚定到unitigs上，穿过复杂的重复区域(tangles)以解决组装歧义并填补缺口

Tools: verkko, hifiasm, GraphAligner, minigraph

Input: 初始组装图、ONT超长读长

Output: 简化的组装图、填补后的contigs

Parameters: - verkko_method : GraphAligner比对后使用读长穿线算法 - hifiasm_method : 类似minigraph的算法在unitig空间进行

Example Command:

```
verkko -d asm --hifi hifi_reads.fq.gz --nano ont_reads.fq.gz
```

Best Practice Note: 超长读长对解析复杂重复区域至关重要，即使中等覆盖度(10x)也能显著改善组装连续性。此步骤可解决大部分tangles，但仍需长距离数据完成染色体级别组装。

Step 5: 单倍型定相（二倍体样本）

Description: 利用家系数据或Hi-C数据对单倍型进行定相，将contigs分配到父本或母本染色体

Tools: hifiasm, verkko, GFase, YaHS

Input: 组装图、父母本测序数据(trio)或Hi-C数据

Output: 定相后的contigs、单倍型分组信息

Parameters: - trio方法：识别仅出现在一个亲本中的k-mers来标记unitigs的亲本来源 - HiC方法：吸引-排斥力平衡模型（相同Hi-C片段的contigs相互吸引，高序列相似性的contigs相互排斥）

Example Command:

```
hifiasm -o output -t 32 --h1 pat.yak --h2 mat.yak hifi_reads.fq.gz
```

Best Practice Note: 家系数据(trio)是最可靠的定相方式。Hi-C定相在acro染色体和微染色体上可能存在问题，需要人工检查。当无亲本数据时，可利用印记甲基化标记推断亲本来源。

Step 6: 染色体级别支架构建

Description: 使用Hi-C数据将contigs排序和定向，构建染色体长度的scaffolds

Tools: YaHS, SALSA, GFase

Input: 定相后的contigs、Hi-C reads

Output: 染色体级别的scaffolds (FASTA, AGP格式)

Parameters: - YaHS：推荐用于HiFi组装的高质量Hi-C scaffolding - HiC片段密度：用于判断contigs是否在相同染色体上

Example Command:

```
yahs -o output scaffolds.fasta hi_c.bam
```

Best Practice Note: YaHS已取代SALSA成为VGP和DToL项目的首选scaffolder。对于性染色体，可能需要手动调整参数。

Step 7: 组装质量评估

Description: 多维度评估组装的完整性、准确性和定相质量

Tools: BUSCO, Compleasm, Merqury, yak, KAT, Flagger, Asset, Inspector, QUAST, asmgene

Input: 最终组装结果(FASTA)、原始测序reads、可选参考基因组

Output: 质量评估报告(QV值、完整性、定相准确性等)

Parameters: - BUSCO : 比对保守单拷贝蛋白基因 - Compleasm : 改进版 BUSCO, 更准确的蛋白-基因组比对 - Merqury_yak : $QV = -10 \cdot \log_{10}(\text{错误率})$, 基于k-mer存在性评估 - KAT : 比较组装和reads的k-mer谱 - asmgene : 基于cDNA-参考比对评估基因完整性

Example Command:

```
merqury.sh reads.fq.gz assembly.fasta out_prefix  
busco -i assembly.fasta -o output -m geno -l lineage
```

Best Practice Note: 应使用多种评估工具: BUSCO/Compleasm评估基因完整性, Merqury/yak评估碱基准确性(QV), KAT检测错误重复或缺失序列。对于有参样本, asmgene可评估多拷贝基因的保留情况。

Databases Used

- NCBI基因组数据库 (隐含)
- Ensembl基因组注释 (隐含)
- UniProt蛋白数据库 (隐含)
- BUSCO保守基因数据库(lineage-specific datasets)
- 物种特异性谱系数据库(用于BUSCO/Compleasm评估)

Key Methodological Findings

- PacBio HiFi reads (10-20 kb, 错误率<0.5%) 是目前高质量基因组组装的核心数据类型
- ONT超长读长 (>100 kb) 对于解析复杂重复区域 (如着丝粒) 至关重要, 即使中等覆盖度也能显著改善组装

- 现代组装器 (verkko、hifiasm、HiCanu) 能够自动化生成接近端粒到端粒 (T2T) 的染色体组装
- 家系数据 (trio) 是最可靠的基因组范围定相方法, 优于Hi-C定相
- ≥ 15 倍单倍型覆盖度的准确长读长是获得连续组装的必要条件
- 重复序列 (特别是卫星重复和片段重复) 仍是最大的组装挑战
- 当前组装器在二倍体和单倍体基因组上表现优异, 但多倍体 (如四倍体土豆) 和癌症基因组组装仍是未解决问题
- 端粒到端粒组装不仅要求覆盖所有染色体, 还必须不含大规模组装错误
- 评估工具 (BUSCO、Merqury、KAT) 组合使用可全面评估组装质量, 但针对不同物种需要调整标准
- 尽管技术进步巨大, 目前仍无法完全自动化地组装所有染色体达到T2T水平, 复杂区域需要人工辅助