

FNet: Mixing Tokens with Fourier Transforms

Paper Information

- **Paper ID:** 2105_03824v4
- **Data Type:** 自然语言处理文本数据 (NLP)。预训练使用C4语料库 (Colossal Clean Crawled Corpus), 微调使用GLUE基准测试, 长序列评估使用Long-Range Arena (LRA) 基准测试
- **Organism:** 不适用 (本研究为自然语言处理/深度学习研究, 非生物信息学)
- **Pages Analyzed:** 18
- **Figures Extracted:** 0

Analysis Pipeline

Step 1: 数据预处理与分词

Description: 使用SentencePiece对C4语料库进行子词分词, 构建词汇表

Tools: SentencePiece

Input: 原始文本数据 (C4数据集)

Output: 分词后的序列, 词汇表大小32,000

Parameters: - `vocabulary_size` : 32000 - `training_subset` : C4数据集中的1亿句子 - `tokenizer_type` : SentencePiece (语言无关的子词分词器)

Example Command:

未提供具体命令

Best Practice Note: 使用SentencePiece进行语言无关的子词分词, 适用于大规模NLP预训练

Step 2: 模型架构配置

Description: 配置FNet编码器架构，用傅里叶变换层替代自注意力层。每个编码器块包含傅里叶混合子层和前馈子层

Tools: JAX, Flax框架

Input: 模型配置参数

Output: 初始化的FNet模型 (Base或Large配置)

Parameters: - `base_configuration` : {'hidden_dimension_dh': 768, 'num_layers': 12, 'num_attention_heads': 12, 'feed_forward_size': '4 * dh = 3072', 'parameters_count': '83M (FNet) vs 112M (BERT)'} -
`large_configuration` : {'hidden_dimension_dh': 1024, 'num_layers': 24, 'num_attention_heads': 16, 'feed_forward_size': '4 * dh = 4096', 'parameters_count': '238M (FNet) vs 339M (BERT)'} -
`fourier_implementation` : {'gpu_all_lengths': '快速傅里叶变换 (FFT)', 'tpu_short_sequences_le_4096': '矩阵乘法 (DFT矩阵)', 'tpu_long_sequences_gt_4096': 'FFT'}

Example Command:

见附录A.7的Flax实现代码

Best Practice Note: 傅里叶变换实现为2D DFT: 先对序列维度应用 `F_seq`，再对隐藏维度应用 `F_h`，仅保留实部

Step 3: 预训练

Description: 在C4数据集上进行掩码语言模型 (MLM) 和下一句预测 (NSP) 预训练

Tools: JAX/Flax, TPU (4×4 v3 chips), GPU (8 V100 chips)

Input: 分词后的文本序列

Output: 预训练模型检查点

Parameters: - `training_steps` : 1,000,000 步 - `batch_size` : {'tpu': 256, 'gpu': 64} - `sequence_lengths` : [512, 1024, 2048, 4096, 8192] - `learning_rates` : ['1e-3', '1e-4'] - `optimizer` : Adam (BERT默认配置) - `xla_precision` : {'matrix_dft_reproduction': 'HIGHEST (高精度)', 'training_convergence': 'DEFAULT (足够)'}

Example Command:

未提供具体命令

Best Practice Note: 混合层无可学习参数的模型 (FNet, Random, FF-only) 在训练过程中表现出更好的稳定性

Step 4: 下游任务微调

Description: 在GLUE基准测试的各项任务上进行微调评估

Tools: GLUE Benchmark

Input: 预训练的FNet模型

Output: 任务特定的预测结果和准确率指标

Parameters: - `tasks` : ['MNLI', 'QQP', 'QNLI', 'SST-2', 'CoLA', 'STS-B', 'MRPC', 'RTE'] - `evaluation_metrics` : 准确率、F1分数、Spearman相关系数 (依任务而定) - `trials` : {'base_model': 3, 'large_model': 6} - `hybrid_configuration` : 将最后2个傅里叶层替换为自注意力层 (FNet-Hybrid)

Example Command:

未提供具体命令

Best Practice Note: 对每个基础学习率进行多次试验，报告最佳结果，不使用提前停止

Step 5: 长序列评估

Description: 在Long-Range Arena (LRA) 基准测试上评估长序列建模能力

Tools: Long-Range Arena (LRA) Benchmark

Input: 预训练模型

Output: ListOps、Text、Retrieval、Image、Pathfinder、Path-X任务的准确率

Parameters: - `sequence_lengths_tested` : [512, 1024, 2048, 4096, 8192, 16384] - `tasks` : {'listops': '层次结构预测', 'text': '文本分类', 'retrieval': '文档检索', 'image': 'CIFAR-10分类 (1层最佳)', 'pathfinder': '路径寻找 (学习率0.001)', 'path_x': '长路径寻找 (大多数模型失败)'} - `hyperparameter_search` : {'num_layers': '[1,2,3,4] (CIFAR-10使用1层)', 'embedding_dimension': '在范围内搜索 (未指定)', 'batch_size': '在范围内搜索 (未指定)'}

Example Command:

未提供具体命令

Best Practice Note: Text和Retrieval任务的结果在不同运行间变化较大，报告最佳结果

Step 6: 性能基准测试

Description: 比较不同架构的训练速度、推理速度和内存使用

Tools: GPU (8 V100 chips), TPU (4×4 v3 chips)

Input: 模型实现

Output: 训练速度 (steps/sec)、推理延迟 (ms/batch)、峰值内存 (GB)、GFLOPS

Parameters: - `measurements` : ['训练速度 (每秒步数)', '推理速度 (每批次毫秒数)', '峰值内存使用 (GB)', '单次前向传播GFLOPS'] - `comparison_baselines` : ['BERT-Base/Large', 'Linear', 'Random', 'FF-only', 'FNet-Hybrid', 'Performer'] - `speed_improvements` : {'gpu_training': '比BERT快80%', 'tpu_training': '比BERT快70%', 'flops_ratio': 'BERT的63%'}

Example Command:

未提供具体命令

Best Practice Note: GPU上FFT在所有测试序列长度(512-8192)都快于矩阵乘法；TPU上短序列(≤ 4096)使用矩阵乘法更快

Databases Used

- C4 (Colossal Clean Crawled Corpus) - 预训练语料库
- GLUE (General Language Understanding Evaluation) - 微调基准测试
- Long-Range Arena (LRA) - 长序列建模基准测试
- SentencePiece词汇模型 (在C4的1亿句子上训练)

Key Methodological Findings

- FNet在GLUE基准上达到BERT 92-97%的准确率，但在GPU上训练速度快80%，TPU上快70%
- 傅里叶变换可以作为无参数.token混合机制完全替代自注意力层
- FNet使用FFT的 $O(N \log N)$ 复杂度，可高效扩展到长序列(最高16384 tokens)
- 混合模型(仅2层自注意力+傅里叶层)可达BERT 97-99%准确率，同时保持40-70%的速度提升
- 在TPU上，序列长度 ≤ 4096 时使用矩阵乘法计算DFT比FFT更快；更长序列则FFT更优
- GPU实现在所有测试序列长度(512-8192)上都优先使用FFT而非矩阵乘法
- FNet内存占用比BERT更轻量，因为混合层没有可学习参数

Report generated by Paper Reader Workflow