

Advances in Machine Learning, Statistical Methods, and AI for Single-Cell RNA Annotation Using Raw Count Matrices in scRNA-seq Data

Paper Information

- **Paper ID:** 2406_05258v1
- **Data Type:** 单细胞RNA测序(scRNA-seq)原始计数矩阵数据
- **Organism:** 未指定 (综述性论文, 适用于多种生物体)
- **Pages Analyzed:** 31
- **Figures Extracted:** 0

Analysis Pipeline

Step 1: 数据预处理与质量控制

Description: 过滤低质量细胞和基因, 处理缺失值 (dropout事件), 确保下游分析的数据可靠性。

Tools: 质控过滤 (未指定具体软件)

Input: 原始scRNA-seq计数矩阵

Output: 过滤后的高质量表达矩阵

Parameters: - 线粒体基因表达百分比阈值 : 未指定 - 最小基因数阈值 : 未指定
- 最小细胞数阈值 : 未指定

Example Command:

未提供具体命令（论文为综述性质）

Best Practice Note: 建议移除线粒体基因比例>20-25%的细胞，以及表达基因数异常低或高的细胞。常用工具包括Seurat的PercentFeatureSet函数或Scanpy的sc.pp.filter_cells/sc.pp.filter_genes。

Step 2: 数据标准化

Description: 调整原始计数数据，使基因和细胞间的比较更有意义，稳定方差。

Tools: Log Normalization, Scaling

Input: 过滤后的计数矩阵

Output: 标准化表达矩阵

Parameters: - Log转换公式： $\log(x + 1)$ - Scaling方法：减去均值并除以标准差（使每基因均值为0，方差为1）

Example Command:

```
Seurat: NormalizeData(normalization.method = 'LogNormalize', scale.factor = 10000)
```

Best Practice Note: 对数转换可减小高表达基因的影响；Scaling对PCA等算法至关重要，确保各基因贡献均等。

Step 3: 批次效应校正

Description: 去除不同实验批次引入的技术差异，同时保留生物学变异。

Tools: ComBat, Harmony

Input: 标准化后的多批次数据

Output: 批次校正后的表达矩阵或嵌入空间

Parameters: - ComBat：基于经验贝叶斯框架，跨基因借用信息 - Harmony：迭代过程将细胞投影到共享嵌入空间

Example Command:

```
ComBat: sva::ComBat(dat, batch); Harmony: harmony::RunHarmony(object,
```

Best Practice Note: ComBat适用于表达水平校正，Harmony特别适用于整合多样数据集并在嵌入空间对齐。

Step 4: 特征选择

Description: 识别高变基因 (HVGs)，降低维度并聚焦于具有生物学意义的信号。

Tools: 高变基因识别 (未指定具体算法)，NMF, 随机森林特征重要性

Input: 标准化表达矩阵

Output: 高变基因子集

Parameters: - 变异性度量：未指定具体方法 - 基因数量：通常为2000-5000个高变基因

Example Command:

```
Seurat: FindVariableFeatures(nfeatures = 2000); Scanpy: sc.pp.highly_
```

Best Practice Note: 特征选择可显著减少计算复杂度，提高聚类 and 可视化效果。建议在多个数据集上验证所选基因的稳定性。

Step 5: 降维分析

Description: 将高维基因表达数据降至低维空间，便于可视化和后续分析。

Tools: PCA, t-SNE, UMAP, Autoencoders, scVAE, DRjCC

Input: 标准化后的表达矩阵 (通常基于高变基因)

Output: 低维嵌入表示 (如2D/3D可视化坐标)

Parameters: - PCA：线性降维，捕获最大方差 - t-SNE：非线性，保留局部结构；关键参数perplexity (通常30-50) 和learning rate - UMAP：非线性，同时保

留局部和全局结构；计算效率更高 - **Autoencoders**：基于神经网络的特征提取和降噪

Example Command:

```
Seurat: RunPCA(); RunUMAP(dims = 1:30); Python: scanpy.tl.umap()
```

Best Practice Note: PCA通常作为初始降维步骤；UMAP推荐用于大规模数据集，平衡效率与结构保持；t-SNE适合精细聚类可视化但计算成本高。降维前Scaling对PCA尤为重要。

Step 6: 细胞聚类

Description: 基于基因表达谱将细胞分组为不同亚群，识别细胞类型和状态。

Tools: k-means, 层次聚类, 图聚类 (Louvain算法), Consensus Clustering, DESC, scGMAI, SIMLR, NMF, 深度聚类

Input: 降维后的嵌入矩阵或标准化表达矩阵

Output: 细胞簇标签

Parameters: - **k-means**：需预先指定k值 - **层次聚类**：无需预指定簇数，生成树状图 - **Louvain**：基于图的社区发现，优化模块度 - **Consensus Clustering**：重采样评估稳定性 - **DESC**：深度嵌入，迭代学习簇特异性特征并去除批次效应

Example Command:

```
Seurat: FindNeighbors(dims = 1:30); FindClusters(resolution = 0.5); S
```

Best Practice Note: 图聚类 (Louvain/Leiden) 对scRNA-seq复杂结构表现最佳；需通过分辨率参数调控簇粒度。建议使用多种方法交叉验证，Consensus Clustering可评估稳定性。

Step 7: 细胞类型注释与分类

Description: 将细胞簇分配给预定义的细胞类型，或使用监督学习进行自动分类。

Tools: SingleR, SCINA, SVM, Random Forests, Neural Networks, Transfer Learning, Ensemble Methods, CNNs/RNNs

Input: 聚类结果或标准化表达矩阵

Output: 细胞类型标签

Parameters: - **SingleR** : 基于与参考数据集的相关性比较, 自动注释 -
SCINA : 基于已知标记基因的半监督分类 - **SVM** : 核函数选择和参数调优关键 -
Random Forests : 可评估特征重要性

Example Command:

```
SingleR::SingleR(test = data, ref = reference, labels = reference$lab
```

Best Practice Note: SingleR适用于无标记基因知识的自动化注释;
SCINA在标记基因明确时更精确。建议结合领域知识验证注释结果,
Ensemble方法可整合多模型预测提高鲁棒性。

Step 8: 差异表达分析

Description: 识别不同细胞簇或条件间显著差异表达的基因。

Tools: Wilcoxon Rank-Sum Test, Likelihood Ratio Test

Input: 聚类标签和标准化表达矩阵

Output: 差异表达基因列表及统计显著性

Parameters: - **Wilcoxon Test** : 非参数检验, 对异常值稳健 - **Likelihood Ratio Test** : 比较包含/不包含变量的模型拟合度 - **p值校正** : 通常使用FDR/Benjamini-Hochberg校正

Example Command:

```
Seurat: FindAllMarkers(test.use = 'wilcox'); Scanpy: sc.tl.rank_genes
```

Best Practice Note: Wilcoxon检验适用于两两比较; 似然比检验可处理复杂实验设计。建议设置log2FC阈值 (如0.25) 筛选生物学显著基因。

Step 9: 模型评估

Description: 使用多种指标评估聚类 and 分类模型的性能。

Tools: 交叉验证, 独立测试集

Input: 模型预测结果和真实标签 (如有)

Output: 性能评估报告

Parameters: - 评估指标 : ['accuracy', 'precision', 'recall', 'F1-score'] - 验证方法 : k-fold交叉验证

Example Command:

```
sklearn.metrics.classification_report(); sklearn.model_selection.cross_val_score()
```

Best Practice Note: 对于无监督聚类, 建议使用 silhouette score、ARI (调整兰德指数) 等指标。对于有监督分类, 应使用独立测试集避免过拟合。

Step 10: 高级AI技术应用 (可选)

Description: 应用深度学习技术进行特征提取、降噪、数据增强和关系建模。

Tools: Autoencoders, Graph Neural Networks (GNNs), Generative Adversarial Networks (GANs), scVAE, DESC, TDM

Input: 原始或标准化表达矩阵

Output: 降噪后数据、合成数据、改进的嵌入表示

Parameters: - Autoencoders : 学习压缩表示用于降噪和特征提取 - GNNs : 建模细胞间关系网络, 提升聚类和分类 - GANs : 生成合成scRNA-seq数据用于数据增强

Example Command:

未提供具体代码 (前沿方法)

Best Practice Note: 深度学习方法需要大规模数据和计算资源。

Autoencoders适合降噪和预训练；GNNs在考虑细胞空间关系时特别有用；GANs可缓解数据稀缺问题。

Databases Used

- 明确提及
- 推荐实践
- note

Key Methodological Findings

- PCA、t-SNE和UMAP是降维核心工具：t-SNE准确性最高但计算成本高；UMAP在稳定性和效率上表现最佳，适合大规模数据集
- 图聚类方法（如Louvain）在处理scRNA-seq复杂结构时优于k-means和层次聚类，能有效识别稀有细胞亚群
- 批次效应校正中，Harmony通过嵌入空间对齐，比ComBat更适合整合多样化的数据集
- 深度学习方法（Autoencoders、GNNs、GANs）在特征提取、降噪和数据增强方面展现巨大潜力
- 自动化注释工具SingleR和SCINA显著提高了细胞类型鉴定效率，分别适用于无先验知识和有标记基因的场景
- TDM、scGMAI、DRjCC和DESC等先进方法在特定任务上优于传统工具如Seurat
- 共识聚类（Consensus Clustering）通过重采样技术提供了稳健的聚类验证策略
- 集成学习方法（Ensemble Methods）通过多模型预测结合，提升了注释的准确性和鲁棒性